AI Pilot 2라운드 완료보고

음성 기반 주차권 예약 Agent

"말로 끝나는 주차 예약"

세바스찬 · 올뤼버 · 로저

2026.02.13

운전 중 주차 예약의 현실

회의에 늦어 강남역으로 달리는 중. 주차장 예약을 해야 하는데...

운전 중

앱 실행 — 목적지 검색 — 핀 탐색 — 주차장 선택 — 권종 선택 — 입차시간 설정 — 차량 확인 — 쿠폰 적용 — 결제수단 선택 — 결제 진행 — 결제 완료

최대 12단계, 최대 15분 소요 — 운전 중에 불가능에 가까운 행동

UT 참여자들의 실제 반응

"운전하면서 앱으로 예약은 불가능해 보였다." — 로니
"빨간불에서만 가능" — 참여자 다수
"살려면 당연히 음성을 쓸 듯" — 무디

이건 소수의 문제가 아닙니다

출처: Amplitude 퍼널 분석 (2026.02.03~04, 샘플 500명 / 유효 301명)

25.7%
주차 직전/직후(10분 이내) 구매 유저 비율
Amplitude 퍼널

일 ~6,900명
이동 중 결제 추정 유저 수
DAU 27K × 25.7%

63%
구매 후 1시간 이내 입차 (이동 중 구매)
Amplitude 퍼널

2분 15초
이동 중 결제 리드타임 중앙값
Amplitude 퍼널

유저의 1/4이 이동 중에 구매합니다. 이 유저들에게 음성은 필요가 아니라 당연함.

리드타임 분석 상세

- 51.8%가 3분 이내 구매 완료 — 절반 이상이 빠르게 끝내고 싶어함
- 17.6%는 1시간 초과 — 사전 계획 구매 패턴
- **결론: 이동 중 급하게 구매하는 유저일수록 음성 Agent의 가치가 큼**

대화형 예약 Agent

Before — 앱 터치

12단계 화면 조작

최대 15분 소요

운전 중 사용: 사실상 불가능 (위험)

After — 음성 Agent

"강남역 근처 주차장 예약해줘"

대화 2~3분 완료

운전 중 사용: 핸즈프리 OK

동작 방식

"강남역 근처 주차장 예약해줘"	음성 → 텍스트 변환	AI Agent가 검색 · 추천 · 구성	텍스트 → 음성 변환	"응, 결제해줘"	결제 완료
유저 음성	STT	LLM + API	TTS	유저 확인	주차권 발행

비용 현실과 안전장치

항목	현재 (PoC)	비고
AI 비용 / 턴	~$0.04	Full-context (맥락 유지 우선)
예약 1건 (6~8턴)	~$0.15~0.30	LLM 비용
STT/TTS	PoC: 로컬 모델	프로덕션: 외부 API or 자체 서버 검토

💡 **트레이드오프**

자연스러운 대화(UX) > 비용 최적화

PoC에서는 UX 우선.
프로덕션 진입 시 최적화 진행:
Prompt 압축, 동적 Tool 바인딩,
컨텍스트 윈도우 관리 등

안전장치 4가지

✅ 결제 전 반드시 사용자 확인

"12,000원 결제할까요?"
동의해야만 결제 실행

✅ API 팩트 기반 응답

주차장 정보를 지어내지 않음
환각(Hallucination) 방지

✅ 무한 루프 방지

턴당 Tool 호출 제한
+ 세션 타임아웃

✅ 에러 핸들링

API 실패, 네트워크 오류 시
안내 후 graceful 종료

이동 중 이탈 유저 1명의 매출 기회 비용을 생각하면, 비용 최적화 경로는 충분히 합리적

우리가 집중한 3가지

① 뭘 말하든 이해하는 Agent

문제
유저는 "강남역 쪽에 오후 5시부터 3시간"
처럼 한번에 말하기도 하고,
"거기 싼 데" 처럼 모호하게 말하기도 함

집중한 것
어떤 표현이든 의도를 잡아내고,
부족한 정보만 자연스럽게 되물어보는
대화 설계

결과
구어체·줄임말·반말 100%
에러/엣지 케이스 100%

② 자연스러운 대화 흐름

문제
Agent가 매 턴 대화를 잊으면
유저가 같은 말을 반복해야 함
→ 음성에서 치명적

집중한 것
Full-context 대화 방식 선택.
비용 트레이드오프를 감수하고
자연스러운 맥락 유지 우선

결과
UT "사람과 대화하는 것 같다"
복합 시나리오 100%

③ 자동 검증 가능한 품질

문제
AI Agent의 품질을
매번 사람이 테스트할 수 없음
→ 프로덕션 품질 보장 불가

집중한 것
LLM-as-Judge +
자율 유저 시뮬레이터로
70개 시나리오 자동 평가

결과
전체 통과율 82.9%
회귀 테스트 인프라 즉시 활용

Usability Test 를 통한 검증

방법	유로트럭 시뮬레이터로 운전 중 상황 재현
참여자	사내 직원 10명, 1:1 세션
Phase A	앱 터치로 예약 시도 (운전 중)
Phase B	음성 Agent로 예약 (운전 중)
비교	같은 사람이 두 방식을 직접 비교

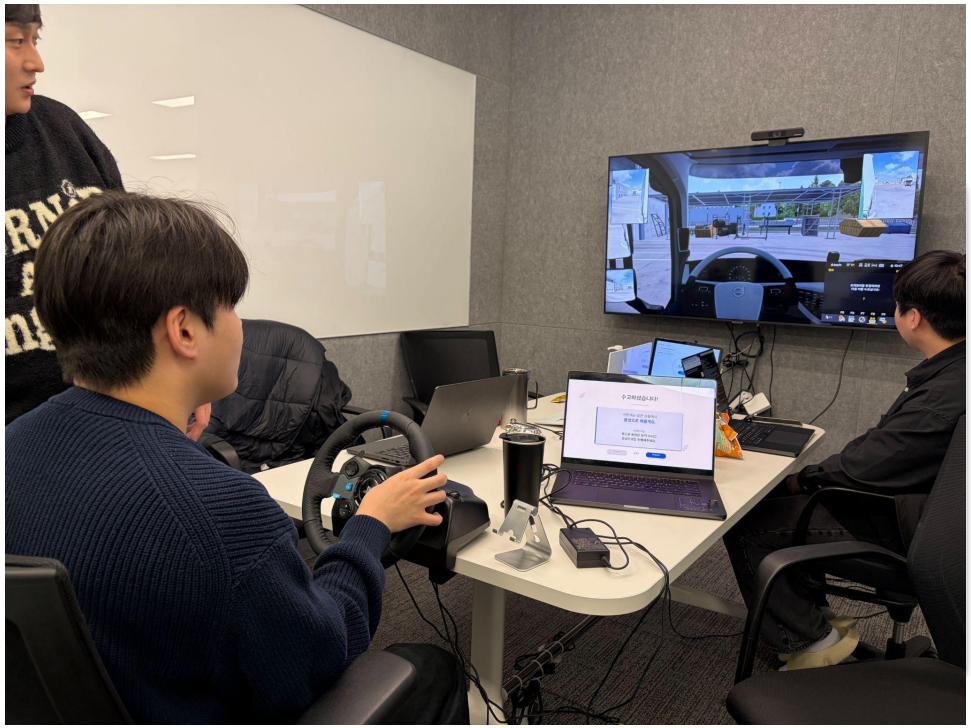

"'운전 중이라고 상상해주세요'라고 하지 않고. 실제와 같은 운전 경험을 통한 검증을 해보고자 했습니다."

평가 3축: UX (사용성) × Revenue (매출 영향) × Agent (기술 품질)

SUS (System Usability Scale) 설문 + 관찰 시트 + 인터뷰

UT보고서: https://socarcorp.atlassian.net/wiki/spaces/park/pages/4398612816/PoC+UT+v2

UT 피드백 반영 사항

참여자 피드백 → 수정 방향 요약

1. 시나리오 및 정보 전달 (UX/UI)

- 발화량 과다 → **최적 1곳만 우선 제안, 거절 시 다음 옵션**
- 주차장명 무의미 → **거리·가격만 간결히 안내**
- 예약 확인 불안 → **결제 전 금액 확인 + 완료 안내 명확화**
- 위치 가늠 어려움 → **지도 핀/내비 연동 안내 추가**

2. 검색 로직 및 필터링 (Search & Logic)

- 차량 특성 필터 부재 → **차량 정보 기반 자동 배제**
- 검색 기준 모호 → **가까운 곳 우선, 저렴한 곳 옵션**
- 앱 플로우 그대로 → **추천→수락/거절→결제 3단계로 축소**

3. 결제 및 개인화 (Payment & Personal.)

- 카드 구분 어려움 → **처음 카드를 선택하도록**
- 패턴 학습 요청 → **과거 이력 기반 선호 우선순위 추천**
- 자동 결제 선호 → **주 사용 카드 즉시 결제 옵션 제공**

4. 성능 (Performance)

- 응답 느림/끊김 → **스트리밍 방식 도입, Latency 최소화**
- 올드한 말투 → **자연스러운 구어체 톤앤매너 적용**

핵심 방향: "적게, 정확하게, 자연스럽게" — 음성에 최적화된 대화 흐름으로 전면 재설계

UT 핵심 결과

발견 1: "운전 중 앱 예약은 사실상 불가능"

참여자 전원 동의
"빨간불에서만 가능"
"살려면 당연히 음성"

발견 2: "음성은 편리하지만 신뢰와 확신이 부족"

주차장을 눈으로 확인 못하는
불확실성 = 가장 큰 심리적 허들
→ 거리 정보, 간결한 안내 필요

발견 3: "적게 말해야 더 잘 들린다"

Agent 발화량 과다
→ 운전 중 인지 부하↑
→ 핵심 정보만 전달해야

참여자 Voice

"운전하면서 앱으로 예약은 불가능해 보였다.
운전 상황에서는 음성 예약의 사용성이
압도적이었다."

— OO

"손을 안 쓰고 예약할 수 있어 어려움 없었음.
에이전트와의 대화가 사람과 대화하는 것 같아
좋았음."

— OO

"출시되면 당연히 사용할 것.
특히 운전 중이나 급할 때."

— OO

출시 시 사용 의향: 10명 중 대다수 4/5점 이상 | "출시되면 당연히 쓸 것" — UT 참여자 다수

UT 세션 현장 사진

김이섭(세바스찬)

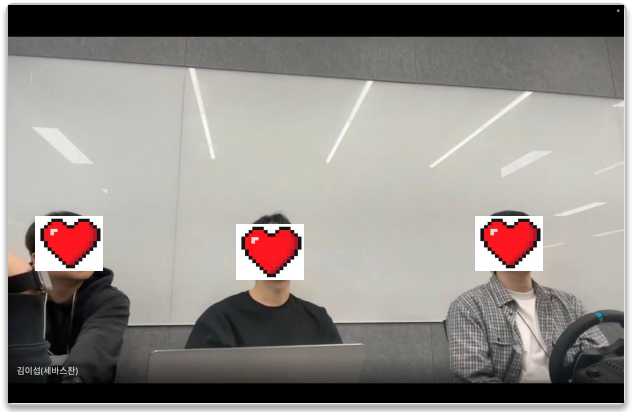
김이섭(세바스찬)

김이섭(세바스찬)

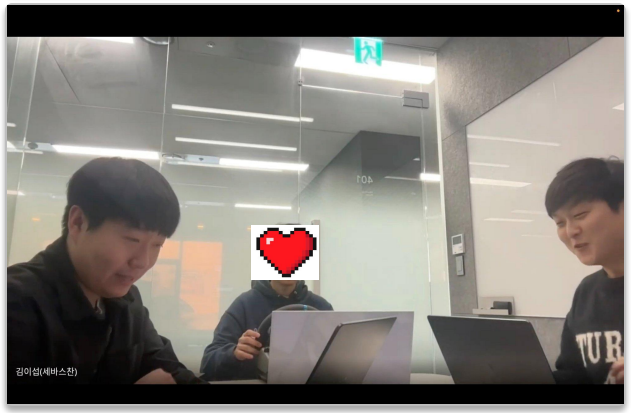
김이섭(세바스찬)

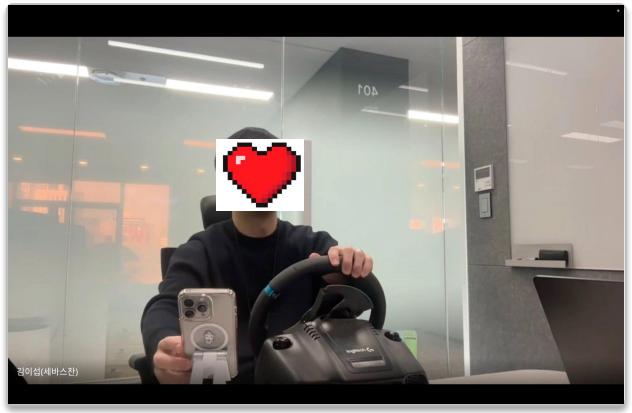
김이섭(세바스찬)

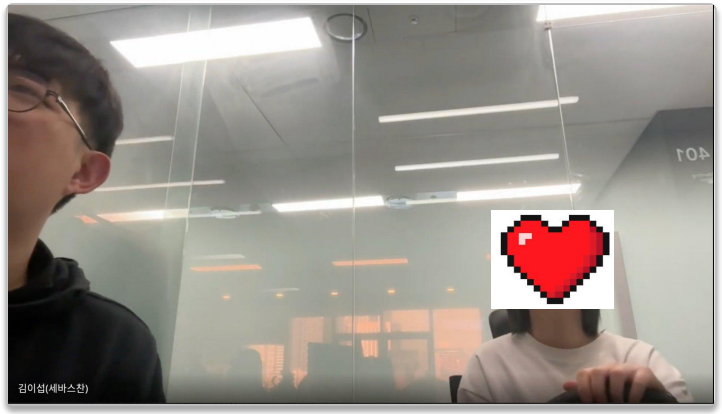
김이섭(세바스찬)

김이섭(세바스찬)

김이섭(세바스찬)

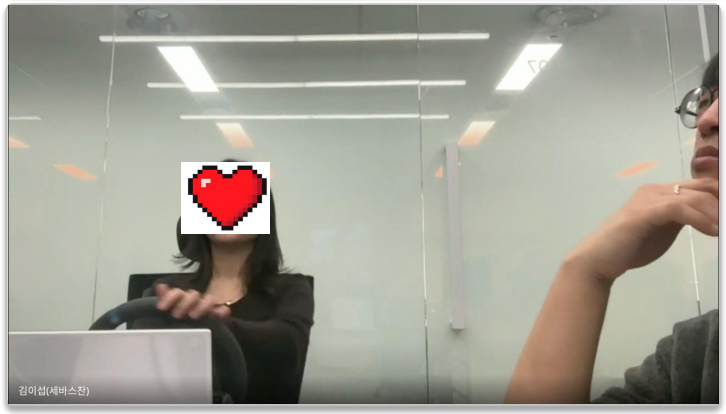
김이섭(세바스찬)

UT 현장

운전 중 앱 사용의 위험성

Agent는 얼마나 잘 하나 — 벤치마크 결과

70개 시나리오 × AI가 유저 역할 + AI가 평가 → 사람 없이 자동 품질 측정 (LLM-as-Judge)

82.9%
전체 통과율 (58/70)
LLM-as-Judge 자동평가

42.8초
시나리오당 평균 시간
70개 시나리오 벤치마크

카테고리	통과율	의미
구어체·줄임말·반말	100% ✅	자연스러운 표현 완벽 이해
에러·엣지 케이스	100% ✅	예외 상황 모두 대응
복합 시나리오	100% ✅	조건 변경, 취소+재예약 등
기본 예약	88% 🟡	목적지 기반 표준 플로우
조건 우선순위	80% 🟡	가격/거리 우선순위 반영

개선이 필요한 영역

권종별 (심야권/종일권): 40%
→ 권종 매칭 로직 보강 필요

즉시결제 (재구매): 60%
→ 이력 기반 재구매 플로우 개선

프로덕션 배포 시
회귀 테스트 인프라로 즉시 활용 가능

파트 3 검증 & 성과

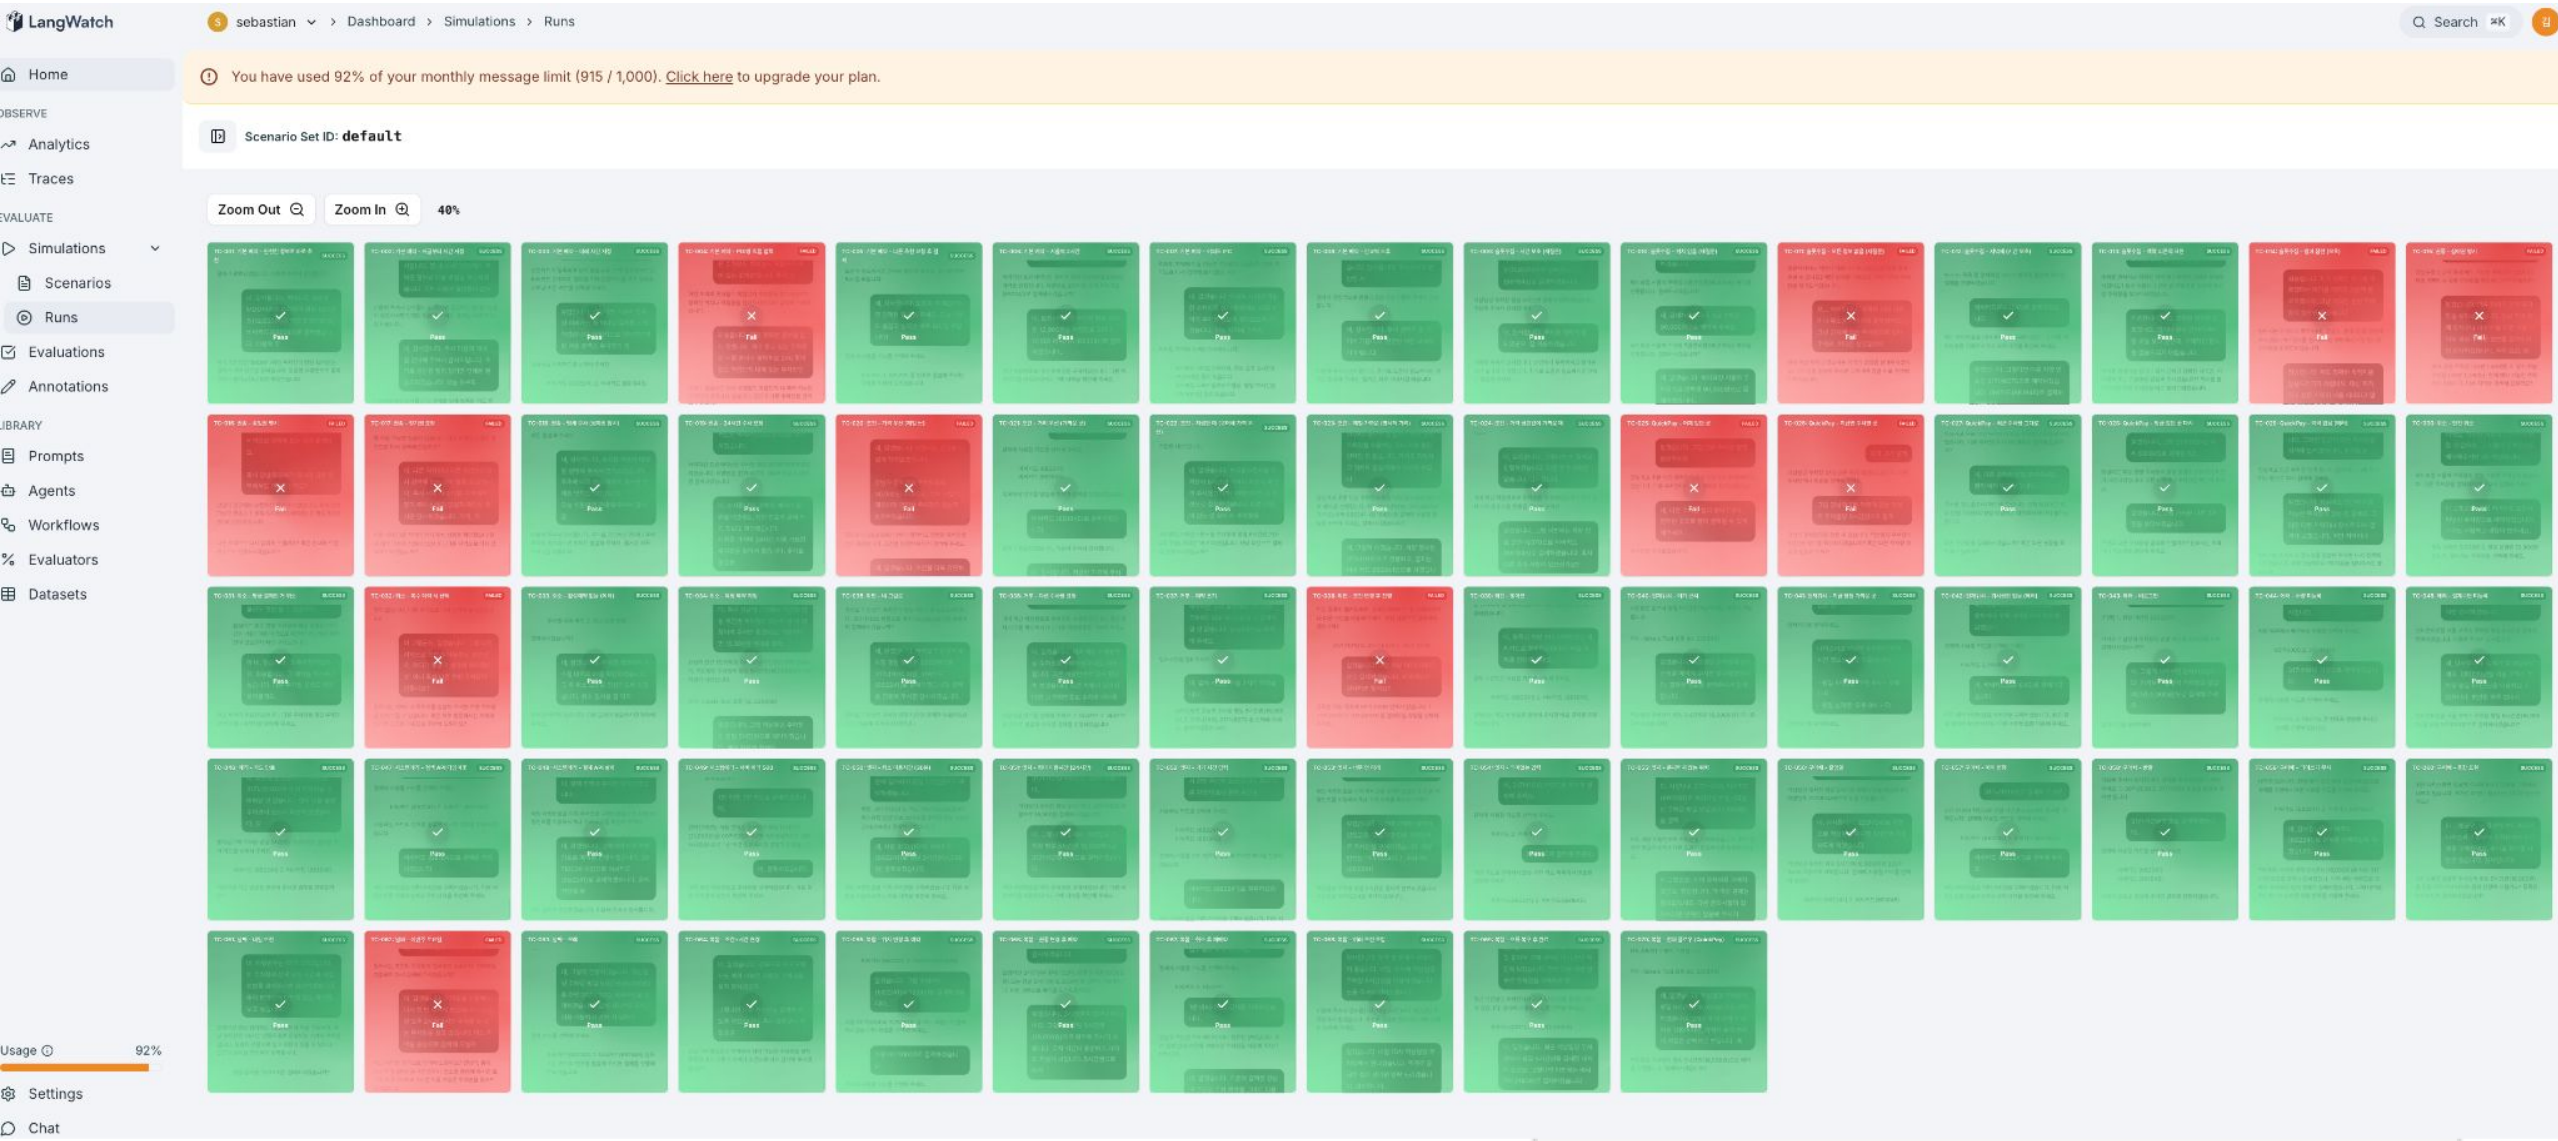
LangWatch
sebastian › Dashboard › Simulations › Runs
Search ⌘K
Home
OBSERVE
Analytics
Traces
EVALUATE
Simulations
Scenarios
Runs
Evaluations
Annotations
LIBRARY
Prompts
Agents
Workflows
Evaluators
Datasets
Usage 92%
Settings
Chat
You have used 92% of your monthly message limit (915 / 1,000). Click here to upgrade your plan.
Scenario Set ID: default
Zoom Out
Zoom In
40%

Voice Parking Agent — System Architecture

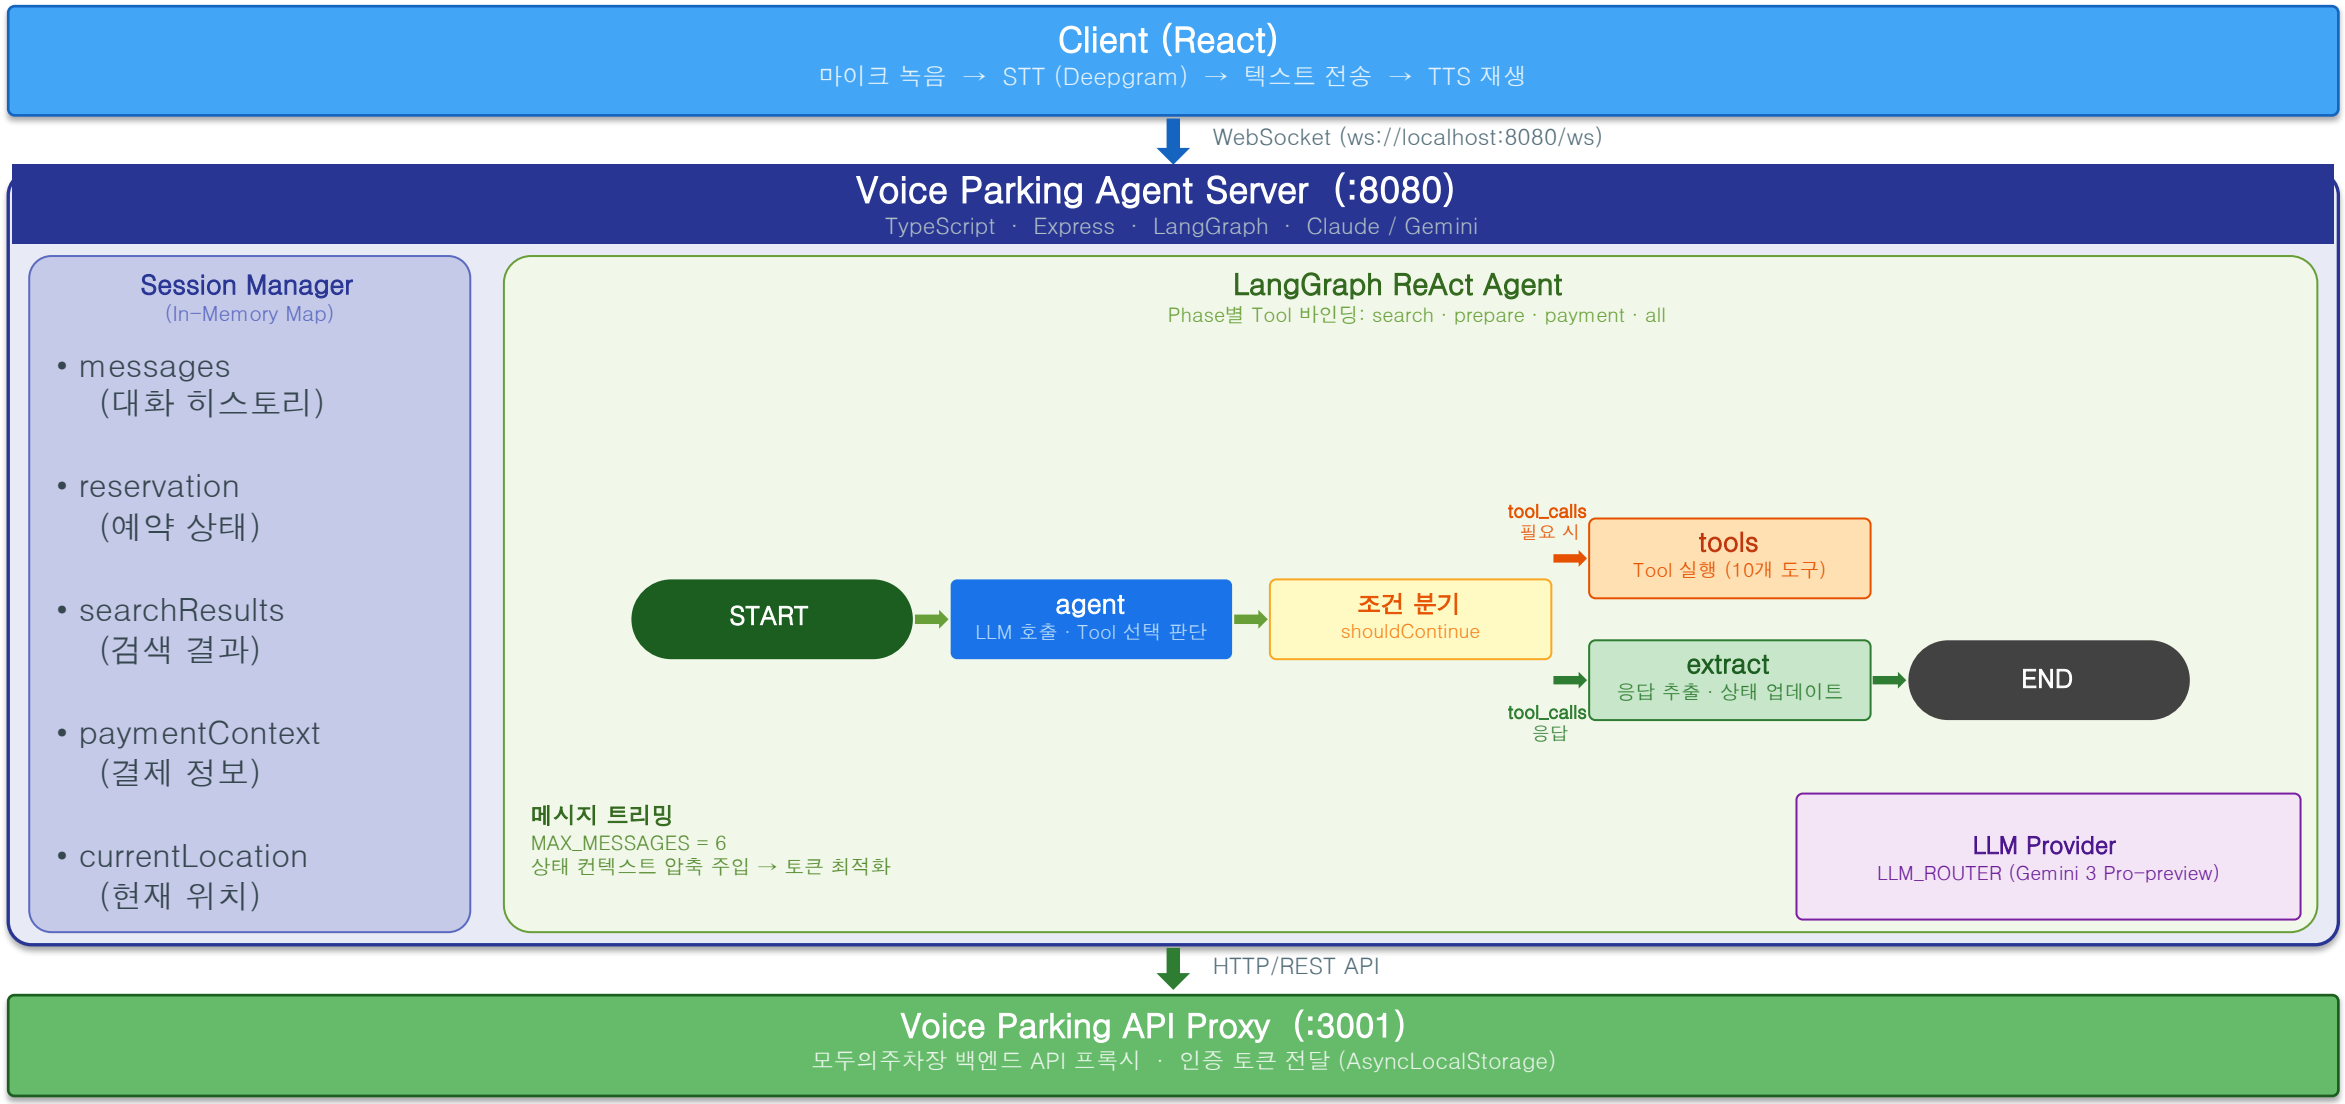

Tools · State · 핵심 설계 결정

Tools (10개)

검색 (4개)
- search_available 위치+시간 기반 주차권 검색 (핵심)
- search 키워드 기반 주차장 검색
- naver_local 네이버 장소 검색 → 좌표 획득
- modu_parking geohash 기반 주차장 검색

예약준비 (3개)
- tickets 주차장 티켓(주차권) 목록 조회
- cars 등록 차량 조회
- cards 등록 카드 조회

결제 (2개)
- pay 주차권 결제 실행
- reg_car 차량 등록

기타 (1개)
- latest 최근 결제 내역 조회

AgentState 상태 구조

- **messages** BaseMessage[]
  대화 히스토리 (최대 6개 유지)
- **reservation** ReservationState
  location, ticket, vehicle, payment
- **searchResults** SearchResultItem[]
  검색된 주차장 리스트
- **paymentContext** PaymentContext
  tickets, cars, cards, 결제 완료
- **currentLocation** {lat, lng}
  사용자 현재 위치
- **response** string
  최종 응답 텍스트
- **nextAction** string
  다음 UI 액션 힌트

WebSocket 통신 흐름

→ connect (token) 연결 수립
→ text_message 음성 텍스트 전송
← agent_status thinking / tool_calling
← agent_status tool: search_available…
← response {text, state, next_action}

핵심 설계 결정

❖ **Stateful 세션**
In-Memory Map에 대화 히스토리 유지
→ 멀티턴 대화 지원

❖ **ReAct 패턴**
LLM이 자율적으로 Tool 호출 결정
→ 규칙 기반 대비 유연성 ↑

❖ **상태 컨텍스트 압축**
시스템 프롬프트에 압축된 상태 주입
→ 토큰 절약 (최대 6 메시지)

❖ **Phase별 Tool 바인딩**
단계에 맞는 도구만 바인딩
→ 입력 토큰 최적화

❖ **최적의 모델**
Gemini 3 Pro-preview
→ 비용-품질 균형

❖ **진행 상태 스트리밍**
agent_status 이벤트로 실시간 UX
→ "검색 중…" 표시

확장 포인트

→ **Observability** LangSmith · LangWatch
→ **배포** 프로덕션 레디 (벤치마크 82.9% 통과)

LIVE DEMO

라이브 데모 진행

시나리오 1 복합 조건 예약

"상황을 자유롭게 가정해봐요"

→ 자유 상황, 자유로운 표현

시나리오 2 재구매 (고임팩트)

"어제 결제한 곳으로 다시 결제해줘"

→ 이력 기반 즉시 재구매 — 실제 이동 중 가장 빈번한 시나리오

프로덕션으로 가고 싶습니다 🚀

PoC로 가능성을 증명했고, UT로 유저 가치도 확인했습니다. 다만 넘어야 할 허들이 있습니다.

🎨 기획·디자인 협업

개발자 3명이 만든 프로토타입
→ 기획자·디자이너 협업 필수
음성 네이티브 워크플로우 재설계

⚖️ AI Agent 결제 법적 규제

AI 통한 결제의 법적 유효성
불명확 (AI기본법, 전자문서법)
→ 법무팀 검토 필수

🔄 새로운 예약 플로우

결제 분리 구조 필요
Agent가 정보 구성
→ 유저가 최종 1-tap 결제

💰 STT/TTS 품질 + 비용 최적화

TTS 스트리밍 + 품질 개선
LLM 비용 최적화 설계
외부 API vs 자체 서버 검토

2026 상반기 로드맵

2~3월

기획·디자인 협업 시작
워크플로우 재설계 + 법적 검토 착수

3~4월

기술 개선 + 새 플로우 개발
TTS 스트리밍 + Agent 최적화

5월

내부 베타 + 법적 검토 완료
사내 클로즈드 베타

6월

앱 내 파일럿 배포
제한된 유저 그룹 운영

그럼에도 꼭 만들고 싶은 이유

유저 25.7%(일 6,900명)에게 실질적 가치 | UT 전원 "출시되면 쓰겠다" | 자체 운영 (인수인계 리스크 없음)

음성 기반 주차권 예약
쏘카 & 모두의주차장이 주차산업의 첫번째가 될 수 있도록
꼭 만들겠습니다.

2주 만에 가능성을 증명했습니다.
10명의 사용자가 운전 중 앱 사용의 위험성을 직접 경험했습니다.
허들은 명확합니다. 해결 방법도 보입니다.
상반기 안에 프로덕션으로 가겠습니다.

별첨 1-1: 과제 요약

항목	내용
풀려고 했던 문제	운전 중 주차권 예약이 12단계·15분 소요 → 위험+불편
배경	① 유저 25.7%가 이동 중 구매 ② 앱 플로우는 운전 중 사실상 불가 ③ 음성 Agent로 대체 가능성 검증
처음 가설	"음성 Agent가 주차 예약 전 과정을 대신하면, 운전 중 예약이 3분 이내에 가능해진다"
결과	Pass / 상태: Experiment

진행 중 변경사항

추가	유로트럭 시뮬레이터 기반 UT (원래 계획에 없었으나 검증력 강화를 위해)
추가	70개 시나리오 자동화 벤치마크 (82.9% 통과)
변경	Claude Agent SDK → LangGraph v2 (상태 기계 설계의 유연성)
시도→복귀	Stateless 시도 → Full-context 복귀 (맥락 유지 우선, 단 최대 6개의 메시지 저장)

✅ 잘된 것

빠른 방향 전환 (SDK→LangGraph, Stateless→Full)
유로트럭 UT → 진짜 운전 중 검증
자동화 벤치마크 → 회귀 테스트 인프라

❌ 잘 안된 것

기획자 없이 개발자끼리 음성 UX 설계
TTS 품질/속도 (UT에서 가장 큰 불만)
벤치마크·비용 모니터링을 후반에야 시작

별첨 1-2: 레슨런 3가지

01

AX는 고치는 것보다 새로 만들자. (2주 만에 기술 스택을 두 번 갈아엎었다)

1주차: Claude Agent SDK로 시작
→ 상태 관리 한계 → LangGraph v2 전환
2주차: 비용 줄이려고 Stateless 시도
→ "아까 그거요" 같은 대화 맥락 끊김
→ Full-context로 복귀

잘된 것: 빠르게 실패하고
빠르게 방향을 전환한 판단

잘 안된 것: 스택 선택에
프로토타입 검증 없이 진입

💡 실험 전에 알았으면

PoC라도 핵심 시나리오 1개를
먼저 end-to-end로 돌려보고
스택을 결정해야 했음

02

UT가 우리의 착각을 깨부쉈다

우리가 만든 것:
앱 플로우를 음성으로 "번역"한 것

UT가 알려준 것:
"Agent 말이 너무 많아"
"주차장 이름만 말해줘"
→ 유저는 한마디로 끝내고 싶다

잘된 것: 유로트럭 UT 설계.
"상상해주세요"가 아닌 진짜 운전

잘 안된 것: 기획자 없이
개발자끼리 UX를 설계함

💡 실험 전에 알았으면

음성 UX는 화면 UX와 완전히 다르다.
기획·디자인 협업이
초기부터 필요했음

03

AI Agent 테스트를 자동화하지 않으면 출시 못한다

처음: 직접 대화하며 수동 테스트
→ 시나리오 늘수록 불가능
→ LLM-as-Judge +
자율 유저 시뮬레이터 구축
70개 시나리오 자동 평가 82.9%

잘된 것: 자동화 벤치마크.
배포 전 회귀 테스트로 즉시 활용

잘 안된 것: 벤치마크를
프로젝트 후반에야 만들었음

💡 실험 전에 알았으면

AI Agent 프로젝트는
"테스트 자동화부터" 만들어야 함.
수동 테스트는 금방 한계에 부딪힘

별첨 1-3: 잘된 것 / 잘 안된 것 요약

✅ 잘된 것

- 빠른 방향 전환 — 안 되면 바로 갈아탄 결단력
- 유로트럭 UT — '상상'이 아닌 진짜 운전으로 검증
- 자동화 벤치마크 — 배포 후에도 쓸 수 있는 인프라
- 구어체·에러·복합 시나리오 100% 통과
- 2주 안에 PoC + UT + 벤치마크 전부 완료

❌ 잘 안된 것

- 기획자 없이 개발자끼리 음성 UX를 설계함
- TTS 품질/속도 — UT 참여자 최대 불만
- 스택 선택 시 프로토타입 검증 없이 진입
- 벤치마크·비용 모니터링을 후반에야 시작

💡 실험 전에 알았으면 좋았을 것

• 핵심 시나리오 1개부터 end-to-end	스택 선택 전에 프로토타입으로 검증. 2번 갈아엎는 비용을 줄였을 것.
• 기획자 참여를 Day 1부터	음성 UX는 화면 UX와 완전히 다르다. 개발자만으로는 한계가 명확했다.
• 테스트 자동화를 프로젝트 초반에	AI Agent는 수동 테스트가 금방 한계에 부딪힌다. 벤치마크부터 만들어야 했다.

별첨 2: AI Agent 결제 법적 규제 상세

쟁점	핵심 내용	근거 법률
AI의 법적 지위	현행 민법은 행위 주체를 자연인/법인으로 한정. AI 대리 결제의 법적 효력 불명확	민법 (의사표시·대리)
자동화된 의사표시	전자문서법 제7조 1항 2호: 자동 프로그램 의사표시 = 작성자 것. 단, AI 자율 판단까지 포괄하는지 논란	전자문서 및 전자거래 기본법
본인확인 절차	현행 체계는 인간 직접 인증 전제. AI 대리 인증의 적법성 불분명	전자서명법, 전자금융거래법
고위험 AI 분류	human-in-the-loop, 투명성 의무 부과. 결제 Agent가 해당될 수 있음	AI 기본법 (2026.1.22 시행)
음성 프라이버시	음성 녹음 = 개인정보. 수집·처리 시 사전 동의 필수	개인정보보호법

대응 방안: Agent가 예약 정보를 구성 → 사용자가 최종 결제 버튼 1번만 터치 (또는 음성 확인)
→ Human-in-the-loop을 법적 요건과 UX 모두 충족하는 방식으로 설계

별첨 3-1: 법적 이슈 — 어떻게 해결할 것인가

핵심 원칙

"Agent는 추천까지, 결제는 사람이" — Agent를 결제 대행자가 아닌, 결제 어시스턴트로 포지셔닝

법적 쟁점	현재 리스크	결제 분리 후 대응	해소
AI의 법적 지위	Agent가 결제를 직접 수행 → AI가 계약 당사자 해석 가능	Agent는 정보 구성만 수행 결제는 유저 명시적 동의 후 처리	✅
자동화된 의사표시	AI 자율 판단에 의한 결제 → 전자문서법 적용 범위 논란	유저가 직접 의사표시 (터치 or 음성 동의)	✅
본인확인 절차	AI 대리 인증의 적법성 불분명	옵션A: 기존 앱 로그인 유지 옵션B: 토스페이먼츠 본인인증	✅
고위험 AI 분류 (AI기본법 2026.1)	Human-in-the-loop 부재 가능 → 규제 대상	결제 전 반드시 유저 확인 = HITL 자연스럽게 충족	✅
비회원 결제 안전성	회원가입 없는 결제의 본인확인 이슈	토스페이먼츠 PG 인증 활용 → 전자금융거래법 준수	✅
음성 프라이버시	음성 데이터 수집·처리 시 동의 필수	최초 사용 시 동의 절차 + 음성 원본 비저장 옵션	🔄

별첨 3-2: 결제 분리 2가지 옵션 & 적용 전략

옵션 A 앱 내 1-tap ⭐ 기본

대상: 기존 쏘카 회원 (결제수단 등록 완료)

🗣️ 음성 요청 → 🤖 Agent 검색·추천·구성
↓
📱 앱 화면에 결제 카드 푸시 → 👆 유저 1-tap 결제
↓
✅ **기존 결제 시스템으로 처리**

✅ 기존 전자상거래 법적 프레임워크 동일
⚠️ 화면 터치 1회 필요 (사실상 핸즈프리 근접)

옵션 B 토스페이먼츠 연동 ⭐ 확장

대상: 비회원 포함 전체 유저 (결제수단 등록 불필요)

🗣️ 음성 요청 → 🤖 Agent 검색·추천·구성
↓
📱 토스페이먼츠 결제 링크 푸시 (앱투앱)
↓
✅ **PG사가 결제 처리 → 콜백 수신**

✅ PG사가 결제 책임 분담 · 비회원 확장 가능
📊 토스 앱 유저 0.8~1.2초 · 성공률 98.7%

구분	옵션 A: 앱 내 1-tap	옵션 B: 토스페이먼츠
대상 유저	기존 쏘카 회원	비회원 포함 전체
결제 속도	1-tap (최소)	토스 앱 0.8~1.2초
법적 구조	기존 전자상거래 동일	PG사가 결제 책임 분담
개발 의존도	기존 결제시스템 연동	독립적 구현 가능
비회원 확장	❌ 불가	✅ 가능

📋 적용 전략

Phase 1 PoC / 파일럿
→ 옵션 B (토스페이먼츠) 단독
비회원 커버 · 독립 구현 · PG 법적 구조

Phase 2 프로덕션
→ 옵션 A + B 병행
회원: 1-tap (더 빠른 UX)
비회원: 토스페이먼츠 (자동 라우팅)

별첨 4: STT/TTS 운영 비용 — 실제 서비스를 위한 준비

🎤 STT (음성→텍스트) 비교

서비스	가격 (1분당)	한국어	실시간	비고
Whisper (로컬)	무료 (GPU 비용)	✅	❌	현재 PoC 사용 중
OpenAI Whisper API	$0.006	✅	❌	가장 저렴한 외부 API
GPT-4o Mini Transcribe	$0.003	✅	❌	최저가 (2026.1~)
Google Cloud STT	$0.016~0.024	✅	✅	실시간 스트리밍 지원
Azure Speech	$0.017	✅	✅	실시간+배치 모두 지원
Deepgram	$0.0043	✅	✅	실시간+저렴

🔊 TTS (텍스트→음성) 비교

서비스	가격 (100만 자)	한국어 품질	스트리밍	비고
Qwen3-TTS (로컬)	무료 (GPU 비용)	보통	❌	현재 PoC 사용 중
OpenAI TTS	$15 (Std) / $30 (HD)	좋음	✅	가성비 최고
ElevenLabs	~$99~180/1M	매우 좋음	✅	최고 품질, 높은 가격
Google Cloud TTS	~$16 (Neural)	좋음	✅	SSML 제어 가능
Azure TTS	$15~16 (Neural)	좋음	✅	커스텀 보이스 가능

별첨 4-2: 예약 1건당 예상 비용 시뮬레이션

가정: 예약 1건 = 대화 6~8턴, STT 약 1분, TTS 약 800자 (한국어)

구성	LLM	STT	TTS	합계/건	월 1만건
현재 PoC (로컬 STT/TTS)	~$0.20	무료 (로컬)	무료 (로컬)	$0.20	$2,000 + GPU 서버
옵션 A: 가성비형 Whisper + OpenAI TTS	~$0.20	$0.006	$0.012	$0.22	$2,200
옵션 B: 고품질형 Whisper + ElevenLabs	~$0.20	$0.006	$0.08~0.14	$0.29~0.35	$2,900~3,500
옵션 C: 실시간형 Deepgram + OpenAI TTS	~$0.20	$0.004	$0.012	$0.22	$2,200
옵션 D: 올인원형 Google STT + Google TTS	~$0.20	$0.016	$0.013	$0.23	$2,300

📋 프로덕션 권장 전략

Phase 1 (파일럿): 옵션 A 가성비형

Whisper API + OpenAI TTS Std

→ 건당 $0.22, 빠른 검증

Phase 2 (정식): 트래픽에 따라 자체 서버 전환 검토

월 3,000시간 이상 → 자체 호스팅 비용 우위

💡 핵심 인사이트

STT/TTS 비용 < LLM 비용의 10%

→ 비용의 90%는 LLM (Claude/GPT)

UT P0 피드백: TTS 품질이 UX 핵심

→ 비용보다 품질·지연시간이 우선

→ 스트리밍 TTS 전환이 최우선 과제